

第7章：岭回归

马学俊(主讲) 杜悦(助教)

苏州大学
数学科学学院

<https://xuejunma.github.io/>

Outline

- 1 岭回归估计的定义
- 2 岭回归估计的性质
- 3 岭迹分析
- 4 岭参数 k 的选择
- 5 用岭回归选择变量
- 6 本章小节与评注

岭回归估计的定义

- 普通最小二乘估计带来的问题
 - 当自变量间存在复共线性时，回归系数估计的方差就很大，估计值就很不稳定。在具体取值上与真实值有较大的偏差，有时甚至会出现与实际意义不服的正负号。
- 岭回归的定义
 - 岭回归(Ridge Regression, 简记为RR)提出的想法是很自然的。当自变量间存在复共线性时， $\mathbf{X}'\mathbf{X} \approx 0$ ，我们设想给 $\mathbf{X}'\mathbf{X}$ 加上一个正常数矩阵 $k\mathbf{I}$, ($k > 0$)，那么 $\mathbf{X}'\mathbf{X} + k\mathbf{I}$ 接近奇异的程度就会比 $\mathbf{X}'\mathbf{X}$ 接近奇异的程度小得多。
 - 考虑到变量的量纲问题，我们先对数据做标准化，为了记号方便，标准化后的设计阵仍然用 \mathbf{X} 表示，定义为：

$$\hat{\beta}(k) = (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{y} \quad (7.2)$$

为 β 的岭回归估计，其中 k 称为岭参数。

- 由于假设 \mathbf{X} 已经标准化，所以 $\mathbf{X}'\mathbf{X}$ 就是自变量样本相关阵，(7.2)式计算的实际上是标准化岭回归估计。
- (7.2)式中因变量观测向量 \mathbf{y} 可以经过标准化也可以未经标准化。显然， $\hat{\beta}(k)$ 岭回归做为 β 的估计应比最小二乘估计稳定，
- 当 $k = 0$ 时的岭回归估计就是普通的最小二乘估计。
- 因为岭参数 k 不是唯一确定的，所以得到的岭回归估计 $\hat{\beta}(k)$ 实际是回归参数 β 的一个估计族。

岭回归估计的性质

性质1 $\hat{\beta}(k)$ 是回归参数 β 的有偏估计。

证明：

$$\begin{aligned} E(\hat{\beta}(k)) &= E((\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}) \\ &= (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'E(\mathbf{y}) \\ &= (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{X}\beta \end{aligned}$$

显然只有当 $k = 0$ 时, $E(\hat{\beta}(0)) = \beta$; 当 $k \neq 0$, $\hat{\beta}(k)$ 是回归参数 β 的有偏估计。要特别强调的是 $\hat{\beta}(k)$ 不再是 β 的无偏估计, 有偏性是岭回归估计的一个重要特性。

岭回归估计的性质

性质2 假设岭参数 k 是 \mathbf{y} 的无关的常数时，
 $\hat{\beta}(k) = (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}$ 是最小二乘估计 $\hat{\beta}$ 的一个线性变换，也是 \mathbf{y} 的线性函数。

证明：

$$\begin{aligned}\hat{\beta}(k) &= (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{y} \\ &= (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \\ &= (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{X}\hat{\beta}\end{aligned}$$

所以，岭估计 $\hat{\beta}(k)$ 是最小二乘估计 $\hat{\beta}$ 的一个线性变换，根据定义式 $\hat{\beta}(k) = (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}$ 知 $\hat{\beta}(k)$ 也是 \mathbf{y} 的线性函数。

- 这里需要注意的是，在实际应用中，由于岭参数 k 总是要通过数据来确定，因而 k 也依赖于 \mathbf{y} ，
- **本质上来说**， $\hat{\beta}(k)$ 并非 $\hat{\beta}$ 的线性变换，也不是 \mathbf{y} 的线性函数。

岭回归估计的性质

性质3 对任意的 $k > 0$, $\|\hat{\beta}\| \neq 0$, 总有

$$\|\hat{\beta}(k)\| < \|\hat{\beta}\|$$

这里 $\|\cdot\|$ 是向量的模, 等于向量各分量的平方和。这个性质表明 $\hat{\beta}(k)$ 可看成由 $\hat{\beta}$ 进行某种向原点的压缩。从 $\hat{\beta}(k)$ 的表达式可以看到, 当 $k \rightarrow \infty$ 时, $\hat{\beta}(k) \rightarrow \mathbf{0}$, 即 $\hat{\beta}(k)$ 化为零向量。

性质4 以MSE表示估计向量的均方误差, 则存在 $k > 0$, 使得


$$MSE[\hat{\beta}(k)] < MSE[\hat{\beta}]$$

即


$$\sum_{j=1}^p E[\hat{\beta}_j(k) - \beta_j]^2 < \sum_{j=1}^p D(\hat{\beta}_j)$$

岭迹分析

可以根据岭迹线的形状变化来确定适当的 k 值和进行自变量的选择。




岭迹分析




- (1) 在图(a)中, $\hat{\beta}_j(0) = \hat{\beta}_j > 0$, 且比较大。从古典分析的观点看, 应将 x_j 看作对 y 有重要影响的因素。但 $\hat{\beta}_j(k)$ 的图形显示出相当的不稳定性, 当 k 从零开始增加时, $\hat{\beta}_j(k)$ 显著地下降, 而且迅速趋于 0, 因而失去预测能力。从岭回归的观点看, x_j 对 y 不起重要作用, 甚至可以剔除这个变量。
- (2) 在图(b)中的情况与图(a)中相反, $\hat{\beta}_j = \hat{\beta}_j(0) > 0$, 但很接近 0。从古典回归分析的观点看, x_j 对 y 的作用不大。但随着 k 略增加, $\hat{\beta}_j(k)$ 骤然变为负值, 从岭回归的观点看, x_j 对 y 有显著影响。

岭迹分析



- (3) 在图(c)中, $\hat{\beta}_j = \hat{\beta}_j(0) > 0$, 说明 x_j 比较显著, 但当 k 增加时, $\hat{\beta}_j(k)$ 迅速下降, 且稳定为负值。从古典回归分析的观点看, x_j 对 y 有正影响的显著因素。从岭回归的观点看, x_j 对 y 有负影响的因素。
- (4) 在图(d)中, $\hat{\beta}_1(k)$ 和 $\hat{\beta}_2(k) > 0$ 都很不稳定, 但其和却大体上稳定。这种情况往往发生在自变量 x_1 和 x_2 的相关性很强的场合, 即在 x_1 和 x_2 之间存在多重共线性。因此, 从自变量选择的观点看, 两者只要保留一个就够了。这可以用来解释某些回归系数估计的符号不合理的情形, 从实际观点看, β_1 和 β_2 不应有相反的符号。岭回归分析的结果对这一点提供了一种解释。

岭迹分析



- (5) 从全局看, 岭迹分析可以用来估计在某一具体实例中最小二乘估计是否适用。把所有回归系数的岭迹都描绘在一张图上, 如果这些岭迹线的不稳定性很强, 整个系统呈现比较“乱”的局面, 往往就使人怀疑最小二乘估计是否很好的反映了真实情况, 如图(e)所示。如果情况如图(f)那样, 则我们对最小二乘估计可以有很大的信心。当情况介于(e)和(f)之间时, 我们必须适当选择 k 值。

岭参数 k 的选择

● 岭迹法

岭迹法选择 k 值的一般原则是：

- (1) 各回归系数的岭估计基本稳定；
- (2) 用最小二乘估计时符号不合理的回归系数，其岭估计的符号变得合理；
- (3) 回归系数没有不合乎经济意义的绝对值；
- (4) 残差平方和增大不太多。

岭参数 k 的选择

• 方差扩大因子法

方差扩大因子 c_{jj} 可以度量多重共线性的严重程度。计算岭估计 $\hat{\beta}(k)$ 的协方差矩阵

$$\begin{aligned} D(\hat{\beta}(k)) &= \text{cov}(\hat{\beta}(k), \hat{\beta}(k)) \\ &= \text{cov}((\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}, (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{y}) \\ &= (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\text{cov}(\mathbf{y}, \mathbf{y})\mathbf{X}(\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1} \\ &= \sigma^2(\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1} \\ &= \sigma^2\mathbf{c}(k) \end{aligned}$$

矩阵 $\mathbf{c}(k) = (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1}$ ，其对角元素 $c_{jj}(k)$ 为岭估计的方差扩大因子。不难看出， $c_{jj}(k)$ 随着 k 的增大而减小。

选择 k 的经验做法：选择 k 使所有的方差扩大因子 $c_{jj}(k) \leq 10$ 。

岭参数 k 的选择

- 由残差平方和来确定 k 值

岭估计在减小均方误差的同时增大了残差平方和，我们希望岭回归的残差平方和 $SSE(k)$ 的增加幅度控制在一定的限度以内，可以给定一个大于1的 c 值，要求：

$$SSE(k) < cSSE$$

寻找使上式成立的最大的 k 值。


用岭回归选择变量

岭回归选择变量的原则：

- (1) 在岭回归中设计矩阵 \mathbf{X} 已经中心化和标准化了，这样可以直接比较标准化岭回归系数的大小。可以剔除掉标准化岭回归系数比较稳定且绝对值很小的自变量。
- (2) 随着 k 的增加，回归系数不稳定，震动趋于零的自变量也可以剔除。
- (3) 剔除标准化岭回归系数很不稳定的自变量.如果依照上述去掉变量的原则，有若干个回归系数不稳定，究竟去掉几个，去掉哪几个，这并无一般原则可循，这需根据去掉某个变量后重新进行岭回归分析的效果来确定。

本章小节与评注

岭回归与普通最小二乘的本质区别是：普通最小二乘估计是线性**无偏**估计中最好的，岭回归估计则是**有偏**估计中一个较好的估计。



- 如果一个估计量只有很小的偏差，但它的精度大大高于无偏估计量，人们更愿意选择这个估计量，因为它接近真实参数值的可能性更大。
- 由上图可以看到，估计量 $\hat{\beta}$ 是无偏的，但不精确，而估计量 $\hat{\theta}$ 精确度高却有小的偏差。 $\hat{\theta}$ 落在真值 β 附近的概率远远大于无偏估计量 $\hat{\beta}$

作业

- p.181 7.6
- 扩展阅读：CH10.11